

main.py

④ app.on_event("start up") → fastAPI 처음 커널 때 실행.

async def start_up_event():

print("서버 시작 ~")

initialize_system() → chatbot_logic.py의 initialize_system()

print("시스템 초기화 완료")

chatbot_logic.py,

def initialize_system() → 챗봇 시작시 llm, data, vector_db 등 필요한 리소스 로딩.

global llm, retrievers, approved_templates, rejected_templates

→ global 키워드를 사용해서 함수 내에서 수정 가능하게 함.

if llm is not None:

return

→ 중복 초기화 방지

llm = ChatOpenAI(model="gpt-4o", temperature=0.2)

→ llm 모델 설정, temperature ⇒ 모델의 창의성. (0 ~ 1),
 (보통) (창의적),
 법규와 가이드 라인을 지키게 하기 때문에 보수적인 0.2 선택.

data_dir = ~

참조하는 data 경로 설정.

approved_templates = ~

rejected_templates = ~

from chromadb.config import Settings

docs_compliance = CustomRuleLoader(os.path.join(data_dir, "compliance_rules.txt")).load()

class CustomRuleLoader(BaseLoader):

def __init__(self, file_path: str, encoding: str = 'utf-8'):

self.file_path = file_path

self.encoding = encoding

def load(self) → List[Document]:

docs = []

try:

with open(self.file_path, 'r', encoding=self.encoding) as f:

(content = f.read()) → 파일을 utf-8로 읽어서 content에 저장

Java는 1번 실행시만 가능
같은 기능.

data 읽는 형식.

파일을 따로 불러와서
?

except FileNotFoundError:

print(f" 경고 ~)

return []

→ 파일없는경우 예외 처리.

rule_blocks = re.findall(r'([규칙사항](.2)|[규칙끝])', content, re.DOTALL)

re = 정규 표현식 모듈, 문자열에서 특정 패턴 찾기.

↳ r = '' 을 raw string으로 처리

∴ +자에서 '규칙사항', '규칙끝'을 찾아서 그 블록을 리턴 형태로 각각 rule_blocks에 저장

for block in rule_blocks

lines = block.strip().split('\n')

metadata = {}

page_content = ""

for line in lines → TS_content_section = False

if line.lower().startswith('content'):

TS_content_section = True

page_content += line[len('content:'):].strip() + "\n"
 해상도 정의 ~

continue

if TS_content_section == True:

page_content += line.strip() + "\n"

else:

if ':' in line:

key, value = line.split(':', 1)

metadata[key.strip()] = value.strip()

if page_content:

docs.append(Document(page_content=page_content.strip(), metadata=metadata))

return docs → ∴ docs는 page_content에 compliant +자의 content를 ~~변환~~
metadata에 나머지 데이터를 key: value 값으로 저장.

예시) [규칙사항]

Source: ~

part: ~

Section: ~

rule_id: ~

content:

[규칙 끝]

docs-generation = CustomRuleLoader(~) → rule.txt를 읽어서

page-content = " ~ "
metadata = { } 를 받음

docs-writerlist = [Document (page-content = t) for t in approved-templates]

docs-rejected = [Document (page-content = t) for t in rejected-templates]

Document 객체는 langChain에서 텍스트 데이터를 관리하는 표준형식.

플러시 작성하면. docs-rejected = []

for t in approved-templates:

new-doc = Document (page-content = t)

docs-writerlist.append (new-doc)

여기서 approved-templates = load-by-line(~). → 한 줄씩 잘라서 읽기.

rejected-templates = load-by-separator(~) → ' __ ' 를 기준으로 나눠서 읽기.

embeddings = openAIEmbeddings (model = ~).

Vector-db-path = ~

Client-Setting S = Settings (allow_mixed_telemetry = false)

) 로컬 준비

↳ 익명화된 사용 흔적 데이터. Chroma-db 기밀성에
보내지 않기, 사용 데이터가 자제 내부의 데이터 이
때문에.

def create_db (name, docs)

if docs:

return Chroma.from_documents (docs, embeddings, ~) → 백터 DB 생성

⇒ return Chroma (collection_name = name, embedding_function = embeddings, ~).

↳ 불필요한 코드. data에 없거나 Chroma-db에만 있는 데이터가 있으면 사용됨.

db-compliance = ~

db- ~

db- ~

db-rejected = ~

} → 백터 DB

def create_hybrid_retriever (VectorStore, docs):

if not docs:

return VectorStore.as_retriever (search_kwargs = { "k": 6 })

} docs가 없을 경우 대비
방어코드.

Vector_retriever = VectorStore.as_retriever(Search_kwargs={"k": 5})

→ 의미 기반 검색. 문맥이 비슷한 문서 5개 찾을. 'k'는 값을 바꾸면서 최적의 값 찾기.

keyword_retriever = BM25Retriever.from_documents(docs)

→ 키워드 기반 검색. 요청에 포함된 키워드와 들어있는 문서 찾기.

keyword_retriever.k = 5 → 상위 5개. **추천 변경 가능**

Ensemble_retriever = EnsembleRetriever(retrievers=[vector_retriever, keyword_retriever],
weights=[0.5, 0.5])

→ 두 검색기를 하나로 합쳐서 순위 매기기. weights=[0.5, 0.5]는 가중치 50.50을 주어서 순위 부여.

if Ranker:

compressor = FlashRankRanker(top_n=3)

return ContextualCompressionRetriever(base_compressor=compressor, base_retriever=ensemble_retriever)

return ensemble_retriever.

→ 재정렬: ensemble_retriever에서 부여된 순위를 다시 검토. ensemble_retriever이 현재 10개 들어있고 거기서 top 3를 선정해 그값만 추출.

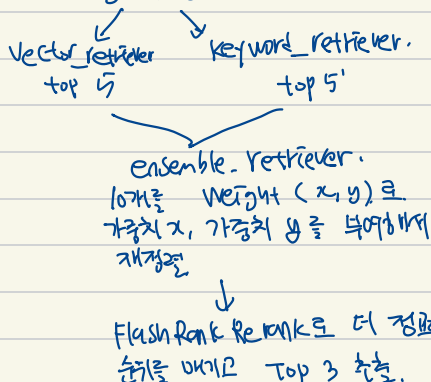
retrievers['compliance'] = create_hybrid_retriever(db_compliance, docs_compliance)

: ['generation'] =

: ['whitelist'] =

: ['rejected'] =

→ 4개의 검색기를 생성. 과정은: 사용자 요청



main.py로 복제, 서버 실행, 초기 라이스 로딩 완료.

채팅 시작.

프론트에서 /api/chat 으로 post 요청.

@app.post("/api/chat")

async def chat(request: ChatRequest) → Dict:

) → 채팅 시작.

session_state = request.state.

class ChatRequest(BaseModel):

message: str

state: Optional[Dict] = Field(default_factory=dict)

주요시 변경.

message ⇒ 필수 입력값.

state ⇒ 선택 입력, 무 입력 → Dict 형식으로 받음, 무 입력 → 빈 Dict 사용

If not session_state:

session_state = {}

'step' =

...

'correction_attempts': 0 }

세션이 비어있다면 초기화.

response_data = process_chat_message(request.message, session_state) → 채팅 메시지에 따라 동작.

chat_logic.py.

def process_chat_message(message: str, state: dict) → dict:

If state['step'] == 'initial':

state['original_request'] = message

state['step'] = 'recommend-templates'

similar_docs = retrievers['whitelist'].invoke(message)

↳ p.4 의 검색기 참고. 실행 버튼 ↳ 사용자에 첫 요청.

if not similar_docs:

state['step'] = 'select_style'

return {

'message': '유사한 기종 템플릿 ~'

'state':

'options': ['기본형', '미키형', '아이템 라스트형']

} → 유사템플릿 못찾으면 이후 강제 느낌.

→ 유사 템플릿 존재

templates = [f'템플릿 {it+1} : \n {doc.page_content}' for i, doc in enumerate(Similar_docs [:3])]

⇒ for i, doc in enumerate (Similar_docs [:3]):

f "템플릿 {it+1} : \n {doc.page_content}"

return {

'message': ~

'state': state

'options': ['템플릿1', '템플릿2', '템플릿3', '신규생성']

'templates':

}

⇒ state에는 변경된 step, original_request가 담겨서 넘겨짐.
recommended-template, ↓ 사용자 요청

elif. State ['step'] == 'recommend-templates':

if message in ['템플릿1', '템플릿2', '템플릿3']:

template_idx = int(message.split() [1]) - 1

Similar_docs = Retriever ['Whitelst'].invoke (State['original-request'])

⇒ Similar_docs를 이미 추출했는데 또 검색기로 추출하는 이유.

BM25, text-embedding, 벡터검색, 순위정렬 (embale, flash rank)

모든 정해진 계산 방식에 의해 검색되고 정렬되므로 결과가 달라지지 않음.

따라서 템플릿을 모두 다 저장하는 것보다 original-request만 저장하고
사용시에만 다시 실행.

State ['template_draft'] = Similar_docs [template_idx].page_content

elif message == '신규생성'

State ['step'] = 'select-style'

return {

'message': '새로운 ~'

'state': state

'options': ['기본형', '이미지형', '아니메이션형']

else. State ['step'] = 'select-style'

return process_chat_message (message, state)

```

if state.get('step') == 'select_style':
    if message in ['기분', '이미지', '아이템리스트']:
        state['selected_style'] = message.
    else:
        state['selected_style'] = '기분'

state['step'] = 'generate_and_validate'
return process_chat_message(message, state)

```

```

if state.get('step') == 'generate_and_validate':
    template_draft = generate_template(state['original_request'], state.get('selected_style', '기분'))

```

```

def generate_template(request: str, style: str) -> str:
    example_docs = retrievers('write[2]') . invoke(request)
    examples = "\n\n" . join([f"### {i+1} : \n { doc.page-content }" for i, doc in enumerate(example_docs)])

```

```

expansion_prompt = ChatPromptTemplate.from_template(
    """" ~ """) => 템플릿 초안 작성 명명.

```

```

expansion_chain = expansion_prompt | llm | StrOutputParser()

```

```

expanded_draft = expansion_chain.invoke(
    {
        "original_request": request,
        "style": style,
        "examples": examples
    }
)

```

→ 작업 명명서
→ 작업자
→ 최종 결과 and 포장

```

return expanded_draft.

```

```

state['template_draft'] = template_draft

```

```

validation_result = validate_template(template_draft)

```

```
def validation_template (draft: str) → dict :
```

```
    parser = JSONOutputParser() ~ ⇒ 출력 형식 준비
```

```
    step_back_prompt = ChatPromptTemplate.from_template(
        """ ~ """)
```

```
    step_back_question = step_back_prompt | llm | StrOutputParser().invoke(f"draft: {draft}")
```

```
    compliance_docs = retrievers['compliance'].invoke(step_back_question)
```

```
    rules_with_metadata = "\n\n", join(~) ⇒ ↓ 검색기에서 추출한 규칙의
                                           규칙 list로 작업
```

```
    rejected_docs = retrievers['rejected'].invoke(draft)
```

```
    rejections = "\n\n", join(~) ⇒ ↓ 위와 같은 작업
```

```
    validation_prompt = ChatPromptTemplate.from_template(
        """ ~ """)
```

```
    validation_chain = validation_prompt | llm | parser
```

```
    result = validation_chain.invoke(~)
```

```
    return result
```

```
State['correction_attempts'] = 0
```

```
if validation_result['status'] == "accepted":
```

```
    state['step'] = "completed"
```

```
    return process_chat_message(message, state) ⇒ Step이 completed로 바뀌어서 다음 단계로 이동
```

```
else
```

```
    state['step'] = 'correction' ⇒ Step이 correction으로 변경.
```

```
    return {
        'message': f'템플릿 ~ '
        'state': state
    }
```

```
}
```

```
elif state['step'] == 'correction':
```

```
    if state['correction_attempts'] < MAX_CORRECTION_ATTEMPTS:
```

```
        corrected_template = correct_template(state)
```



```

def correct_template(state: dict) → Str:
    attempts = state.get('correction_attempts', 0) ⇒ correction_attempts
    if attempts == 0:
        instruction = "3. ~"
    elif attempts == 1:
        instruction = "3. ~"
    else:
        instruction = "" 3. ~ ""
    correction_prompt_template = "" ~ ""
    correction_prompt = ChatPromptTemplate.from_template(correction_prompt
        ~ template)
    correction_prompt = correction_prompt.partial(dynamic_instruction =
        instruction)

```

시도 횟수별 프롬프트 변화
 광고성 문구 제거
 ↓
 쿠팡, 알인 등과 같은 키워드 제거
 ↓
 정제에 맞게 과감한 변화

```

correction_chain = correction_prompt | llm | StrOutputParser()
new_draft = correction_chain.invoke({'original_request': state['original_request'] ~ })
return new_draft.

```

```

state['template_draft'] = corrected_template.
state['correction_attempts'] += 1
validation_result = validate_template(corrected_template) ⇒ 대체검증
state['validation_result'] = validation_result
if validation_result['status'] == "accepted":
    state['step'] = "completed"
    return process_chat_message(message, state) ⇒ completed 단계로 이동
else:
    return process_chat_message(message, state) ⇒ correction 단계로 재시도
else:
    ← MAX_CORRECTION_ATTEMPTS 넘어선 사용자에게
    수정 요청.

```

```

state ['step'] = 'manual - correction'
return {
  'message': ~
  'state': ~
  'options': ['표기하기']
}

```

```

elif state ['step'] = 'manual - correction':

```

```

  if message == '표기하기':
    state ['step'] = 'initial'
    return {
      'message': ~
      'state': ~
    }

```

표기하면 초기단계로 이동

else:

```

state ['template_draft'] = message
validate_result = validate_template (message)

```

검정판제

```

state ['validation_result'] = validation_result

```

```

if validation_result ['state'] == 'accepted':

```

```

  state ['step'] = "completed"

```

```

  return process_chat_message (message, state)

```

else:

```

  return {

```

```

    'message': ~

```

```

    'state': ~

```

```

    'options': ~

```

```

  }

```

```

elif state ['step'] == 'completed':

```

```

  final_template = state.get ('template_draft', "")

```

```

  html_preview = render_final_template (final_template)

```

```
def render_final_template(template_string:str) → Str:
```

} → 일련된 형식의 html로 변경

```
return html_output
```

```
parameterized_result = parameterized_result (final_template)
```

← 템플릿에서 변수로 선택 가능한 부분은 # 변수명으로 설정.

```
return {
    "message":
    "state":
    'template':
    'html_preview':
    'editable_variables'
}
```

```
return {
    'message' : ~
    'state' : ~
}
```

} process_chart_message 종료.